

# 한국어 임베딩

컴퓨터는 자연어의 의미를  
어디까지 이해할 수 있을까

NAVER Chatbot Model  
이기창

# 목차

- 임베딩이란
- 임베딩에 의미를 어떻게 함축하는가
- 단어 수준 임베딩 : Word2Vec, FastText, GloVe, Swivel
- 문장 수준 임베딩 : ELMo, BERT
- CNN, RNN, Transformer가 함축하는 정보
- 임베딩에 문법 정보 녹이기
- 임베딩에 내재한 정보 : 상식, 숫자
- 임베딩 파인튜닝
- Beyond Text

# 임베딩이란

- 단어나 문장을 벡터로 바꾼 것 혹은 그 과정

# 임베딩이란

- 단어나 문장을 벡터로 바꾼 것 혹은 그 과정

구분	메밀꽃 필 무렵	운수 좋은 날	사랑 손님과 어머니	삼포 가는 길
기차	0	2	10	7
막걸리	0	1	0	0
선술집	0	1	0	0

# 임베딩이란

- 단어나 문장을 벡터로 바꾼 것 혹은 그 과정

구분	메밀꽃 필 무렵	운수 좋은 날	사랑 손님과 어머니	삼포 가는 길
기차	0	2	10	7
막걸리	0	1	0	0
선술집	0	1	0	0

문서 임베딩

단어 임베딩

# 임베딩이란

- ‘희망’이라는 단어의 Word2Vec 임베딩

[−0.00209 −0.03918 0.02419 ... 0.01715 −0.04975 0.09300]


# 임베딩이란

- 임베딩으로 할 수 있는 것 : 관련도/유사도 계산

희망	절망	학교	학생	가족	자동차
소망	체념	초등	대학생	아이	승용차
행복	고뇌	중학교	대학원생	부모	상용차
희망찬	절망감	고등학교	고학생	편부모	트럭
꿈	상실감	야학교	교직원	고달픈	대형트럭
열망	번민	중학	학부모	사랑	모터사이클


# 임베딩이란

- 임베딩으로 할 수 있는 것 : 관련도/유사도 계산




# 임베딩이란

- 임베딩으로 할 수 있는 것 : 시각화



# 임베딩이란

- 벡터 연산(유추 평가) : 아들 - 딸 + 소녀 = 소년




# 임베딩이란

- 벡터 연산(유추 평가) : 아들 - 딸 + 소녀 = 소년

단어1	단어2	단어3	결과
아들	딸	소년	소녀
아들	딸	아빠	엄마
아들	딸	남성	여성
남동생	여동생	소년	소녀
남동생	여동생	아빠	엄마
남동생	여동생	남성	여성
신랑	신부	왕	여왕
신랑	신부	손자	손녀
신랑	신부	아빠	엄마



# 임베딩이란

- 전이학습(transfer learning) : 다른 딥러닝 모델의 입력값



# 임베딩이란

- 전이학습(transfer learning) : 다른 딥러닝 모델의 입력값



# 임베딩에 어떻게 의미를 함축하는가


- 임베딩과 관련한 세 가지 철학

구분	백오브워즈 가정	언어 모델	분포 가정
내용	어떤 단어가 (많이) 쓰였는가	단어가 어떤 순서로 쓰였는가	어떤 단어가 같이 쓰였는가
대표 통계량	TF-IDF	–	PMI
대표 모델	Deep Averaging Network	ELMo, GPT	Word2Vec

# 임베딩에 어떻게 의미를 함축하는가

- 백오브워즈 : 어떤 단어가 (많이)쓰였는가

문서의 주제는 문서 내 단어 사용 양상에 드러난다  
순서 정보 무시, 어떤 단어가 (많이)쓰였는가가 중요



# 임베딩에 어떻게 의미를 함축하는가

- 백오브워즈 : 어떤 단어가 (많이)쓰였는가

문서의 주제는 문서 내 단어 사용 양상에 드러난다  
순서 정보 무시, 어떤 단어가 (많이)쓰였는가가 중요

$$\text{TF-IDF}(w) = \text{TF}(w) \times \log\left(\frac{N}{\text{DF}(w)}\right)$$

구분	메밀꽃 필 무렵	운수 좋은 날	사랑 손님과 어머니	샴포 가는 길
담배	0.2603	0.2875	0.0364	0.2932
를	0.0	0.0034	0.0	0.0

# 임베딩에 어떻게 의미를 함축하는가

- 백오브워즈 : 어떤 단어가 (많이)쓰였는가

문서의 주제는 문서 내 단어 사용 양상에 드러난다  
순서 정보 무시, 어떤 단어가 (많이)쓰였는가가 중요





그림 2-2 Deep Averaging Network

# 임베딩에 어떻게 의미를 함축하는가

- 언어모델 : 단어가 어떤 순서로 쓰였는가


단어 등장 순서 정보를 명시적으로 학습

① 발 없는 말이 천리 \_\_



↓  
간다

② 발 없는 말이 \_\_ 간다




# 임베딩에 어떻게 의미를 함축하는가

- 언어모델 : 단어가 어떤 순서로 쓰였는가


단어 등장 순서 정보를 명시적으로 학습

① 발 없는 말이 천리 \_\_



↓  
간다

② 발 없는 말이 \_\_ 간다



↓  
천리

ELMo, GPT…

BERT  
(masked LM)

# 임베딩에 어떻게 의미를 함축하는가

- 분포 가정 : 어떤 단어가 같이 쓰였는가

자연어의 의미는 그 주변 문맥을 통해 유추해 볼 수 있다

체언(명사): 관형사가 그 앞에 올 수 있고 조사가 그 뒤에 올 수 있음

용언(동사/형용사): 부사가 그 앞에 올 수 있고 선어말어미가 그 뒤에 올 수 있고 어말어미가 그 뒤에 와야 함  
관형사: 명사가 그 뒤에 와야 함

부사: 용언, 부사, 절이 그 뒤에 와야 함

조사: 체언 뒤에 와야 함

어미: 용언 뒤에 와야 함

감탄사(간투사): 특별한 결합 제약 없이 즉, 문장 내의 다른 단어와 문법적 관계를 맺지 않고 따로 존재함

# 임베딩에 어떻게 의미를 함축하는가

- 분포 가정 : 어떤 단어가 같이 쓰였는가

자연어의 의미는 그 주변 문맥을 통해 유추해 볼 수 있다

window = 2인 단어-문맥 행렬


		개울가, 에서, 속옷, 빨래, 를, 하는, 남녀							
단어	문맥	개울가	에서	속옷	빨래	를	하는	남녀	total
개울가									
:									
빨래			+1	+1		+1	+1		20
:									
total				15					1000

$$\text{PMI}(A, B) = \log \frac{P(A, B)}{P(A) \times P(B)}$$


# 임베딩에 어떻게 의미를 함축하는가

- 분포 가정 : 어떤 단어가 같이 쓰였는가

자연어의 의미는 그 주변 문맥을 통해 유추해 볼 수 있다



CBOW



Skip-gram

# 임베딩에 어떻게 의미를 함축하는가

- 임베딩과 관련한 세 가지 철학

세 철학은 말뭉치의 통계적 패턴을 서로 다른 각도에서 분석  
상호 보완적

구분	백오브워즈 가정	언어 모델	분포 가정
내용	어떤 단어가 (많이) 쓰였는가	단어가 어떤 순서로 쓰였는가	어떤 단어가 같이 쓰였는가
대표 통계량	TF-IDF	—	PMI
대표 모델	Deep Averaging Network	ELMo, GPT	Word2Vec

# 단어 수준 임베딩

- Word2Vec

## Skip-Gram with Negative Sampling

... 개울가 ( 에서 속옷 빨래 를 하는 ) 남녀 ...  
 $c_1 \quad c_2 \quad t \quad c_3 \quad c_4$

포지티브 샘플

$t$	$c$
빨래	에서
빨래	속옷
빨래	를
빨래	하는

네거티브 샘플

$t$	$c$	$t$	$c$
빨래	책상	빨래	커피
빨래	안녕	빨래	떡
빨래	자동차	빨래	사과
빨래	숫자	빨래	노트북

# 단어 수준 임베딩

- Word2Vec

## Skip-Gram with Negative Sampling


$t, c$ 가 포지티브 샘플( $=t$  주변에  $c$ 가 존재)일 확률

$$P(+|t, c) = \frac{1}{1 + \exp(-\mathbf{u}_t \mathbf{v}_c)}$$

---

$t, c$ 가 네거티브 샘플( $c$ 를  $t$ 와 무관하게 말뭉치 전체에서 랜덤 샘플)일 확률

$$P(-|t, c) = 1 - P(+|t, c) = \frac{\exp(-\mathbf{u}_t \mathbf{v}_c)}{1 + \exp(-\mathbf{u}_t \mathbf{v}_c)}$$




# 단어 수준 임베딩

- Word2Vec

## Skip-Gram with Negative Sampling

행렬 분해 관점에서 이해하는 Word2Vec

$$\mathbf{A}_{ij}^{\text{SGNS}} = \mathbf{U}_i \cdot \mathbf{V}_j = \text{PMI}(i, j) - \log k$$




Levy, O., & Goldberg, Y. (2014). Neural word embedding as implicit matrix factorization. In *Advances in neural information processing systems* (pp. 2177-2185).

# 단어 수준 임베딩


- GloVe

$$\mathcal{J} = \sum_{i,j=1}^{|V|} f(\mathbf{A}_{ij})(\mathbf{U}_i \cdot \mathbf{V}_j + \mathbf{b}_i + \mathbf{b}_j - \log \mathbf{A}_{ij})^2$$



# 단어 수준 임베딩


- Swivel



# 문장 수준 임베딩

- ELMo


CNN + Bi-LSTM



# 문장 수준 임베딩

- CNN이 포착하는 정보


Conv filter : ngram detector (특정 구의 존재/부재 확인)



# 문장 수준 임베딩

- CNN이 포착하는 정보


Max-pooling : threshold filter (불필요한 구 버림)



# 문장 수준 임베딩

- CNN이 포착하는 정보

Max-pooling : threshold filter (불필요한 구 버림)



Jacovi, A., Shalom, O. S., & Goldberg, Y. (2018). Understanding convolutional neural networks for text classification. *arXiv preprint arXiv:1809.08037*.

# 문장 수준 임베딩

- LSTM이 포착하는 정보

Long term dependency (left to right)

context the\_formal study of grammar is an important part of  
education

LSTM

context the\_formal study of grammar is an important part of  
education

GRU

# 문장 수준 임베딩

- ELMo

Fine-tuning 때 학습, 토큰별로 생성

$$\text{ELMo}_k^{\text{task}} = \gamma^{\text{task}} \sum_{j=0}^L s_j^{\text{task}} \mathbf{h}_{k,j}^{\text{LM}}$$




그림 5-19 ELMo 임베딩

# 문장 수준 임베딩

- Transformer block

Self-Attention  
Scale  
Dot-Product  
Multi-head

# 문장 수준 임베딩

- Transformer block

**Self-Attention (Q=K, 문장 길이 관계없이 모든 쌍의 관계 고려)**

Scale

Dot-Product

Multi-head

$$\text{softmax}\left(\frac{\mathbf{Q}\mathbf{K}^\top}{\sqrt{d_k}}\right)\mathbf{V} = \begin{matrix} \text{드디어 금요일 이다} \\ \text{드디어} \\ \text{금요일} \\ \text{이다} \end{matrix} \begin{pmatrix} 0.2 & 0.7 & 0.1 \\ \cdots & \cdots & \cdots \\ \cdots & \cdots & \cdots \end{pmatrix} \begin{pmatrix} \mathbf{V}_{\text{드디어}} \\ \mathbf{V}_{\text{금요일}} \\ \mathbf{V}_{\text{이다}} \end{pmatrix}$$
$$= \text{금요일} \begin{pmatrix} 0.2\mathbf{V}_{\text{드디어}} + 0.7\mathbf{V}_{\text{금요일}} + 0.1\mathbf{V}_{\text{이다}} \\ \cdots \\ \cdots \end{pmatrix}$$

그림 5-22 Scaled Dot-Product Attention 예시

# 문장 수준 임베딩

- Transformer block

Self-Attention  
**Scale**

Dot-Product  
Multi-head

$$\text{softmax}\left(\frac{\mathbf{Q}\mathbf{K}^\top}{\sqrt{d_k}}\right)\mathbf{V} = \begin{array}{c|ccc} & \text{드디어} & \text{금요일} & \text{이다} \\ \text{드디어} & 0.2 & 0.7 & 0.1 \\ \text{금요일} & \cdots & \cdots & \cdots \\ \text{이다} & \cdots & \cdots & \cdots \end{array} \begin{pmatrix} \mathbf{V}_{\text{드디어}} \\ \mathbf{V}_{\text{금요일}} \\ \mathbf{V}_{\text{이다}} \end{pmatrix}$$

$$= \begin{array}{c|c} \text{드디어} & 0.2\mathbf{V}_{\text{드디어}} + 0.7\mathbf{V}_{\text{금요일}} + 0.1\mathbf{V}_{\text{이다}} \\ \text{금요일} & \cdots \\ \text{이다} & \cdots \end{array}$$

그림 5-22 Scaled Dot-Product Attention 예시

소프트맥스 그래디언트

$$\frac{\partial \mathbf{y}_i}{\partial \mathbf{x}_i} = \mathbf{y}_i(1 - \mathbf{y}_i)$$

$$\frac{\partial \mathbf{y}_i}{\partial \mathbf{x}_j} = -\mathbf{y}_i \mathbf{y}_j$$

# 문장 수준 임베딩

- Transformer block

Self-Attention  
Scale

**Dot-Product (Q, K 간 유사도 포착 + 계산 효율 높음)**

Multi-head

$$\text{softmax}\left(\frac{\mathbf{Q}\mathbf{K}^\top}{\sqrt{d_k}}\right)\mathbf{V} = \begin{array}{c|ccc} & \text{드디어} & \text{금요일} & \text{이다} \\ \text{드디어} & 0.2 & 0.7 & 0.1 \\ \text{금요일} & \cdots & \cdots & \cdots \\ \text{이다} & \cdots & \cdots & \cdots \end{array} \begin{pmatrix} \mathbf{V}_{\text{드디어}} \\ \mathbf{V}_{\text{금요일}} \\ \mathbf{V}_{\text{이다}} \end{pmatrix}$$

$$= \text{금요일} \begin{pmatrix} 0.2\mathbf{V}_{\text{드디어}} + 0.7\mathbf{V}_{\text{금요일}} + 0.1\mathbf{V}_{\text{이다}} \\ \cdots \\ \cdots \end{pmatrix}$$

그림 5-22 Scaled Dot-Product Attention 예시

# 문장 수준 임베딩

- Transformer block

Self-Attention

Scale

Dot-Product

**Multi-head (여러 명의 독자)**

$$\text{MultiHead}(\mathbf{Q}, \mathbf{K}, \mathbf{V}) = \text{Concat}(\text{head}_1, \dots, \text{head}_h) \mathbf{W}^O$$

$$\text{head}_i = \text{Attention}(\mathbf{Q}\mathbf{W}_i^Q, \mathbf{K}\mathbf{W}_i^K, \mathbf{V}\mathbf{W}_i^V)$$

# 문장 수준 임베딩

- BERT

Bi-directional Language Model

①

나는 어제 \_\_\_\_\_



②

나는 어제 \_\_\_\_\_ 먹었다



# 문장 수준 임베딩

- BERT

Bi-directional Language Model

$$\text{softmax}\left(\frac{\mathbf{QK}^\top}{\sqrt{d_k}}\right)\mathbf{V} = \begin{matrix} & 꿈 & 보다 & 해몽 \\ 꿈 & \begin{pmatrix} 0 & 0 & 0 \\ 1.0 & 0 & 0 \\ 0.9 & 0.1 & 0 \end{pmatrix} \\ 보다 & & & \\ 해몽 & & & \end{matrix} \begin{pmatrix} \mathbf{V}_{\text{꿈}} \\ \mathbf{V}_{\text{보다}} \\ \mathbf{V}_{\text{해몽}} \end{pmatrix}$$

정답

$$= \begin{matrix} & 꿈 & \\ 꿈 & \begin{pmatrix} 0 \cdot \mathbf{V}_{\text{꿈}} + 0 \cdot \mathbf{V}_{\text{보다}} + 0 \cdot \mathbf{V}_{\text{해몽}} \\ 1.0 \mathbf{V}_{\text{꿈}} + 0 \cdot \mathbf{V}_{\text{보다}} + 0 \cdot \mathbf{V}_{\text{해몽}} \\ 0.9 \mathbf{V}_{\text{꿈}} + 0.1 \mathbf{V}_{\text{보다}} + 0 \cdot \mathbf{V}_{\text{해몽}} \end{pmatrix} \\ 보다 & \\ 해몽 & \end{matrix}$$

꿈  
보다  
해몽

그림 5-27 GPT의 학습

# 문장 수준 임베딩

- BERT

Bi-directional Language Model

$$\text{softmax}\left(\frac{\mathbf{QK}^\top}{\sqrt{d_k}}\right)\mathbf{V} = \begin{matrix} & [\text{MASK}] & \text{보다} & \text{해몽} \\ \begin{matrix} \text{[MASK]} \\ \text{보다} \\ \text{해몽} \end{matrix} & \begin{pmatrix} 0.3 & 0.1 & 0.6 \\ \cdots & \cdots & \cdots \\ \cdots & \cdots & \cdots \end{pmatrix} & \begin{pmatrix} \mathbf{V}_{[\text{MASK}]} \\ \mathbf{V}_{\text{보다}} \\ \mathbf{V}_{\text{해몽}} \end{pmatrix} \end{matrix}$$

정답

$$= \begin{matrix} \text{[MASK]} & \boxed{0.3\mathbf{V}_{[\text{MASK}]} + 0.1\mathbf{V}_{\text{보다}} + 0.6\mathbf{V}_{\text{해몽}}} \\ \text{보다} & \cdots \\ \text{해몽} & \cdots \end{matrix} \quad \begin{matrix} \text{꿈} \\ \cdot \\ \cdot \end{matrix}$$

그림 5-28 BERT의 학습

# 문장 수준 임베딩

- BERT

Bi-directional Language Model

Tasks	Dev Set				
	MNLI-m (Acc)	QNLI (Acc)	MRPC (Acc)	SST-2 (Acc)	SQuAD (F1)
BERT <sub>BASE</sub>	84.4	88.4	86.7	92.7	88.5
No NSP	83.9	84.9	86.5	92.6	87.9
LTR & No NSP	82.1	84.3	77.5	92.1	77.8
+ BiLSTM	82.1	84.1	75.7	91.6	84.9

GPT




그림 5-29 BERT 대 GPT 성능 차이(Devlin et al., 2018)

# 문장 수준 임베딩

- BERT

## Masked Language Model

- 전체 학습 데이터 토큰의 15%를 마스킹한다.
- 마스킹 대상 토큰 가운데 80%는 실제 빈칸으로 만들고, 모델은 그 빈칸을 채운다. 예: **발 없는 말이 [MASK] 간다 → 천리**
- 마스킹 대상 토큰 가운데 10%는 랜덤으로 다른 토큰으로 대체하고, 모델은 해당 위치의 정답 단어가 무엇일지 맞추도록 한다. 예: **발 없는 말이 [컴퓨터] 간다 → 천리**
- 마스킹 대상 토큰 가운데 10%는 토큰 그대로 두고, 모델은 해당 위치의 정답 단어가 무엇일지 맞추도록 한다. 예: **발 없는 말이 [천리] 간다 → 천리**

# 문장 수준 임베딩

- BERT



## Masked Language Model

- **발 없는 말이 [MASK] 같다**의 빈칸을 채워야 하기 때문에 문장 내 어느 자리에 어떤 단어를 쓰는 게 자연스러운지 앞뒤 문맥을 읽어낼 수 있게 된다.
- **발 없는 말이 천리 같다** **발 없는 말이 컴퓨터 같다**를 비교해 보면서 주어진 문장이 의미/문법상 비문인지 아닌지 가려낼 수 있다.
- 모델은 어떤 단어가 마스킹될지 전혀 모르기 때문에 문장 내 모든 단어 사이의 의미적, 문법적 관계를 세밀히 살피게 된다.

## 문장 수준 임베딩

- Transformer의 dynamics

언어모델과 기계번역 모델은 입력 정보를 갈수록 잊는다  
즉, 새로운 정보(다음 또는 번역 토큰)를 생성하는데 주목한다




Voita, E., Sennrich, R., & Titov, I. (2019). The bottom-up evolution of representations in the transformer: A study with machine translation and language modeling objectives. *arXiv preprint arXiv:1909.01380*.

# 문장 수준 임베딩

- Transformer의 dynamics


트랜스포머의 하위 레이어에서는 syntactic 정보(POS 등)를,  
상위 레이어에서는 semantic 정보(Coref. 등)를 함축한다



# 임베딩에 문법 정보 녹이기

- Continual Learning


catastrophic forgetting 막기 위해 순차적으로 학습



# 임베딩에 문법 정보 녹이기

- Continual Learning


catastrophic forgetting 막기 위해 순차적으로 학습



# 임베딩에 문법 정보 녹이기

- Continual Learning

catastrophic forgetting 막기 위해 순차적으로 학습



# 임베딩에 문법 정보 녹이기

- Word-aware Pre-training task

## Knowledge Masking Task

개체(named entity), 구(phrase) 단위 마스킹 (ERNIE1.0)  
continual learning의 최초 모델에 적용

## Capitalization Prediction Task

해당 단어가 대문자인지 소문자인지 예측

## Token-Document Relation Prediction task

해당 토큰이 원본 문서의 다른 segment에 나타나는지 예측  
키워드(동일 문서에 자주 나타나는 단어) 파악 가능

# 임베딩에 문법 정보 녹이기

- Structure-aware Pre-training task

## Sentence Reordering Task

원래 세그먼트를 1~m개로 나누고 랜덤 셔플한 뒤 순서 맞추기  
문장 간 관계를 파악하게 됨

## Sentence Distance task

3범주 분류 문제

0=동일 문서 앞뒤 문장

1=앞뒤는 아니지만 동일 문서

2=다른 문서에서 뽑힌 두 문장

# 임베딩에 문법 정보 녹이기

- Semantic-aware Pre-training task

## Discourse Relation Task

두 문장이 의미적으로, 비유적으로 유사한지 여부 예측

## Sentence Distance task

앞 문장을 쿼리/뒤 문장을 검색 문서 제목으로 간주, 3 범주 분류 문제

0=강한 관련성, 쿼리를 실제 검색했을 때 해당 문서 제목을 클릭



1=약한 관련성, 해당 쿼리를 던지면 검색은 되지만 미클릭

2=관련성 제로

# 임베딩에 내재한 정보

- 사고력/상식의 원천은 곧 암기이다?

## Knowledge Graph vs Language Model



e.g. ELMo/BERT

Petroni, F., Rocktäschel, T., Lewis, P., Bakhtin, A., Wu, Y., Miller, A. H., & Riedel, S. (2019). Language Models as Knowledge Bases?. *arXiv preprint arXiv:1909.01066*.

# 임베딩에 내재한 정보

- 사고력/상식의 원천은 곧 암기이다?


어휘 문법 정보뿐 아니라 지식까지 통으로 외운다

Relation	Query	Answer	Generation	
P19	Francesco Bartolomeo Conti was born in ____.	Florence	Rome [-1.8], <b>Florence</b> [-1.8], Naples [-1.9], Milan [-2.4], Bologna [-2.5]	
P20	Adolphe Adam died in ____.	Paris	<b>Paris</b> [-0.5], London [-3.5], Vienna [-3.6], Berlin [-3.8], Brussels [-4.0]	
P279	English bulldog is a subclass of ____.	dog	dogs [-0.3], breeds [-2.2], <b>dog</b> [-2.4], cattle [-4.3], sheep [-4.5]	
P37	The official language of Mauritius is ____.	English	<b>English</b> [-0.6], French [-0.9], Arabic [-6.2], Tamil [-6.7], Malayalam [-7.0]	
P413	Patrick Oboya plays in ____ position.	midfielder	centre [-2.0], center [-2.1], <b>midfielder</b> [-2.4], forward [-2.4], midfield [-2.7]	
P138	Hamburg Airport is named after ____.	Hamburg	Hess [-7.0], Hermann [-7.1], Schmidt [-7.1], <b>Hamburg</b> [-7.5], Ludwig [-7.5]	
P364	The original language of Mon Oncle Benjamin is ____.	French	<b>French</b> [-0.2], Breton [-3.1], English [-3.8], Dutch [-4.2], German [-4.9]	
P54	Dani Alves plays with ____.	Barcelona	Santos [-2.4], Porto [-2.5], Sporting [-3.1], Brazil [-3.3], Portugal [-3.7]	
P106	Paul Toungui is a ____ by profession.	politician	lawyer [-1.1], journalist [-2.4], teacher [-2.7], doctor [-3.0], physician [-3.7]	
P527	Sodium sulfide consists of ____.	sodium	water [-1.2], sulfur [-1.7], <b>sodium</b> [-2.5], zinc [-2.8], salt [-2.9]	
P102	Gordon Scholes is a member of the ____ political party.	Labor	Labour [-1.3], Conservative [-1.6], Green [-2.4], Liberal [-2.9], <b>Labor</b> [-2.9]	
P530	Kenya maintains diplomatic relations with ____.	Uganda	India [-3.0], <b>Uganda</b> [-3.2], Tanzania [-3.5], China [-3.6], Pakistan [-3.6]	
P176	iPod Touch is produced by ____.	Apple	<b>Apple</b> [-1.6], Nokia [-1.7], Sony [-2.0], Samsung [-2.6], Intel [-3.1]	
P30	Bailey Peninsula is located in ____.	Antarctica	<b>Antarctica</b> [-1.4], Bermuda [-2.2], Newfoundland [-2.5], Alaska [-2.7], Canada [-3.1]	
P178	JDK is developed by ____.	Oracle	IBM [-2.0], Intel [-2.3], Microsoft [-2.5], HP [-3.4], Nokia [-3.5]	
P1412	Carl III used to communicate in ____.	Swedish	German [-1.6], Latin [-1.9], French [-2.4], English [-3.0], Spanish [-3.0]	
P17	Sunshine Coast, British Columbia is located in ____.	Canada	<b>Canada</b> [-1.2], Alberta [-2.8], Yukon [-2.9], Labrador [-3.4], Victoria [-3.4]	
P39	Pope Clement VII has the position of ____.	pope	cardinal [-2.4], Pope [-2.5], <b>pope</b> [-2.6], President [-3.1], Chancellor [-3.2]	
P264	Joe Cocker is represented by music label ____.	Capitol	EMI [-2.6], BMG [-2.6], Universal [-2.8], <b>Capitol</b> [-3.2], Columbia [-3.3]	
P276	London Jazz Festival is located in ____.	London	<b>London</b> [-0.3], Greenwich [-3.2], Chelsea [-4.0], Camden [-4.6], Stratford [-4.8]	
P127	Border TV is owned by ____.	ITV	Sky [-3.1], <b>ITV</b> [-3.3], Global [-3.4], Frontier [-4.1], Disney [-4.3]	
P103	The native language of Mammootty is ____.	Malayalam	<b>Malayalam</b> [-0.2], Tamil [-2.1], Telugu [-4.8], English [-5.2], Hindi [-5.6]	
P495	The Sharon Cuneta Show was created in ____.	Philippines	Manila [-3.2], <b>Philippines</b> [-3.6], February [-3.7], December [-3.8], Argentina [-4.0]	
ConceptNet	AtLocation	You are likely to find a overflow in a ____.	drain	sewer [-3.1], canal [-3.2], toilet [-3.3], stream [-3.6], <b>drain</b> [-3.6]
	CapableOf	Ravens can ____.	fly	<b>fly</b> [-1.5], fight [-1.8], kill [-2.2], die [-3.2], hunt [-3.4]
	CausesDesire	Joke would make you want to ____.	laugh	cry [-1.7], die [-1.7], <b>laugh</b> [-2.0], vomit [-2.6], scream [-2.6]
	Causes	Sometimes virus causes ____.	infection	disease [-1.2], cancer [-2.0], <b>infection</b> [-2.6], plague [-3.3], fever [-3.4]
	HasA	Birds have ____.	feathers	wings [-1.8], nests [-3.1], <b>feathers</b> [-3.2], died [-3.7], eggs [-3.9]
	HasPrerequisite	Typing requires ____.	speed	patience [-3.5], precision [-3.6], registration [-3.8], accuracy [-4.0], <b>speed</b> [-4.1]
	HasProperty	Time is ____.	finite	short [-1.7], passing [-1.8], precious [-2.9], irrelevant [-3.2], gone [-4.0]
	MotivatedByGoal	You would celebrate because you are ____.	alive	happy [-2.4], human [-3.3], <b>alive</b> [-3.3], young [-3.6], free [-3.9]
	ReceivesAction	Skills can be ____.	taught	acquired [-2.5], useful [-2.5], learned [-2.8], combined [-3.9], varied [-3.9]
	UsedFor	A pond is for ____.	fish	swimming [-1.3], fishing [-1.4], bathing [-2.0], <b>fish</b> [-2.8], recreation [-3.1]

# 임베딩에 내재한 정보

- 임베딩에 숫자의 의미가 얼마나 포함돼 있을까?

## Numeracy Probing Model



Wallace, E., Wang, Y., Li, S., Singh, S., & Gardner, M. (2019). Do NLP Models Know Numbers? Probing Numeracy in Embeddings. *arXiv preprint arXiv:1909.07940*.

# 임베딩에 내재한 정보

- 임베딩에 숫자의 의미가 얼마나 포함돼 있을까?

임베딩에 숫자 의미 내포 (random vs pretrained)


Transformer보다 CNN 계열이 잘한다 (지역 정보 포착 유리)

Subword보다 Char 단위가 잘한다 (BERT vs ELMo/Char-\*)

Interpolation <i>Integer Range</i>	List Maximum (5-classes)			Decoding (RMSE)			Addition (RMSE)		
	[0,99]	[0,999]	[0,9999]	[0,99]	[0,999]	[0,9999]	[0,99]	[0,999]	[0,9999]
Random Vectors	0.16	0.23	0.21	29.86	292.88	2882.62	42.03	410.33	4389.39
Untrained CNN	0.97	0.87	0.84	2.64	9.67	44.40	1.41	14.43	69.14
Untrained LSTM	0.70	0.66	0.55	7.61	46.5	210.34	5.11	45.69	510.19
Value Embedding	<b>0.99</b>	0.88	0.68	<b>1.20</b>	11.23	275.50	<b>0.30</b>	15.98	654.33
<i>Pre-trained</i>									
Word2Vec	0.90	0.78	0.71	2.34	18.77	333.47	0.75	21.23	210.07
GloVe	0.90	0.78	0.72	2.23	13.77	174.21	0.80	16.51	180.31
ELMo	0.98	0.88	0.76	2.35	13.48	62.20	0.94	15.50	45.71
BERT	0.95	0.62	0.52	3.21	29.00	431.78	4.56	67.81	454.78
<i>Learned</i>									
Char-CNN	0.97	<b>0.93</b>	<b>0.88</b>	2.50	<b>4.92</b>	<b>11.57</b>	1.19	<b>7.75</b>	<b>15.09</b>
Char-LSTM	0.98	0.92	0.76	2.55	8.65	18.33	1.21	15.11	25.37
<i>DROP-trained</i>									
NAQANet	0.91	0.81	0.72	2.99	14.19	62.17	1.11	11.33	90.01
- GloVe	0.88	0.90	0.82	2.87	5.34	35.39	1.45	9.91	60.70


# 임베딩 파인튜닝

- Word Embeddings




# 임베딩 파인튜닝

- ELMo Embeddings



# 임베딩 파인튜닝

- BERT Embeddings



# 튜토리얼

- Code

<https://github.com/ratsgo/embedding>


- Blog

<https://ratsgo.github.io/embedding>

- 도커 환경 구성


```
git clone https://github.com/ratsgo/embedding.git
cd embedding
docker build -t ratsgo/embedding-gpu -f docker/Dockerfile-GPU .
docker run -it --rm --runtime=nvidia ratsgo/embedding-gpu bash
```

# 튜토리얼




# Beyond Text

- Spoken Language Understanding



# Beyond Text

- Spoken Language Understanding



# Beyond Text

- Universal Representation?

